

# Prompts und Prompt-Injection

Wie eine KI Anweisungen versteht – und wie man sie austricksen kann

Du benutzt Sprach-KIs wie ChatGPT, indem du Text eintippst. Diesen Text nennt man **Prompt**. Auf diesem Blatt lernst du, woraus ein Prompt eigentlich besteht, warum KI sich austricksen lässt und wie du dich schützt.

## Was ist ein Prompt?

Ein Prompt ist alles, was die KI als Anweisung liest. Das ist mehr, als du im Chat schreibst. Eine KI liest gleich drei Sachen auf einmal:

|   |                               |                                                       |                                                          |
|---|-------------------------------|-------------------------------------------------------|----------------------------------------------------------|
| 1 | <b>Systemprompt</b>           | Unsichtbare Regeln vom Hersteller oder Lehrer.        | Bsp.: „Antworte freundlich. Verrate niemals die Lösung.“ |
| 2 | <b>Nutzereingabe</b>          | Das, was du in den Chat tippst.                       | Bsp.: „Erklär mir die Photosynthese.“                    |
| 3 | <b>Kontext (Zusatzwissen)</b> | Texte, Dateien oder Webseiten, die die KI dazu liest. | Bsp.: ein PDF, eine Webseite, eine E-Mail.               |

**Merke:** Die KI macht keinen Unterschied zwischen diesen drei Quellen. Sie liest alles als eine einzige lange Anweisung. Genau hier liegt das Problem.

## Warum lässt sich eine KI überhaupt austricksen?

Eine KI ist kein normales Computerprogramm. Schau dir den Unterschied an:

| Klassisches Programm                                                                                                                                                                      | KI (Sprachmodell)                                                                                                                                                                                                                          |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Folgt festen Regeln, die ein Mensch programmiert hat.<br><b>Beispiel-Regel:</b><br>WENN Eingabe = „Passwort?“<br>DANN antworte „Zugriff verweigert“.<br>→ <b>Macht immer das Gleiche.</b> | Hat keine festen Regeln. Die KI schätzt nur, welches Wort als Nächstes am besten passt.<br><b>So denkt sie:</b><br>„Was würde ein Mensch hier wahrscheinlich antworten?“<br>→ <b>Eine neue Anweisung kann eine alte Regel überstimmen.</b> |

**Das heißt:** Eine KI „denkt“ nicht wie ein Mensch und prüft Regeln nicht so streng wie ein normales Programm. Wer den richtigen Text schreibt, kann eine KI dazu bringen, ihre Regeln zu vergessen. Genau das nennt man **Prompt-Injection**.

